

# Inteligencia de Negocio. Práctica 2: Visualización y Segmentación

Patricia Córdoba Hidalgo  
patriciacorhid@correo.ugr.es  
Grupo 2 (Viernes)

27 de noviembre de 2020

# Índice

<b>1. Visualización</b>	<b>3</b>
1.1. Visualización de medidas . . . . .	3
1.2. Curva ROC . . . . .	5
1.3. Análisis de los atributos . . . . .	6
<b>2. Segmentación</b>	<b>10</b>
2.1. Introducción . . . . .	10
2.2. Caso de estudio 1: Choque frontal en carreteras convencionales . . . . .	11
2.2.1. K-means . . . . .	11
2.2.2. DBSCAN . . . . .	15
2.2.3. Comparación de los algoritmos . . . . .	20
2.2.4. Interpretación de la segmentación . . . . .	21
2.3. Caso 2: Fin de semana con densidad de circulación densa . . . . .	22
2.3.1. K-means . . . . .	22
2.3.2. DBSCAN . . . . .	27
2.3.3. Comparación de los algoritmos . . . . .	32
2.3.4. Interpretación de la segmentación . . . . .	32
2.4. Caso 3: Entre semana con densidad de circulación densa . . . . .	33
<b>3. Contenido adicional</b>	<b>33</b>
<b>4. Bibliografía</b>	<b>33</b>


# 1. Visualización

## 1.1. Visualización de medidas


En la práctica 1 se mostraron los datos de cada una de las medidas en tablas, mostrando el valor numérico de éstas. Otra forma de mostrar estos datos es mediante gráficas. En esta práctica, se mostrarán en diagramas de barras los valores de las medidas más utilizadas para la toma de decisiones en la práctica anterior.

Veamos primero los resultados de los diferentes preprocesados de datos:


### Procesado 1



### Procesado 2



### Procesado 3



El código de cada gráfica es:

```
fig, ax = plt.subplots()
ax.bar(["ZeroR", "SVM", "K-nn", "Arbol", "MLP", "RF"], pX_metrica, color='green')
ax.set_title("PX-metrica")
```


Donde “X” es denota el preprocesado que se ha aplicado, 1, 2 o 3, y “metrica” la métrica que se mide, pudiendo ser **accuracy**, **F1-Score**, **TPR** o **FNR**. El vector pX-metrica es un vector donde se guardan los valores de la métrica “metrica” con el preprocesado “X” de todos los modelos considerados.

Podemos observar que los tres preprocesados obtienen resultados muy similares, como ya comentamos en la práctica anterior. A primera vista, la estructura de los diagramas parece la misma, es decir, al ordenar los diferentes modelos


según el valor de la métrica correspondiente con cada procesamiento, este orden es muy parecido en todos ellos, no atreviéndome a decir el mismo por haber barras de alturas semejantes. Es por esto que decantarse por un procesamiento con estos gráficos resulta complicado.

En los tres preprocesamientos el modelo con menor **accuracy** es el ZeroR, seguido del árbol de decisión. El SVM, K-nn y MLP son los modelos con mayor **accuracy** en los tres casos. En el resto de métricas se observa que el SVM y el MLP tienen un mejor desempeño que el K-nn, siendo estos dos modelos los que mejores resultados obtienen. El árbol de decisión y el ZeroR son los modelos que peor desempeño tienen. El Random Forest y el árbol de decisión no obtienen tan buenos resultados como los otros modelos inicialmente pero, como vimos en la práctica 1, aplicando la poda coste-complejidad obteníamos una gran mejora de su desempeño, ya que con esta poda se conseguía reducir el sobreajuste del modelo.


Para elegir que procesamiento utilizabamos en la práctica 1, nos decantamos por el procesamiento que en más modelos tuviese mayor **F1-Score**. En las siguientes gráficas mostramos el valor de esta métrica en los diferentes modelos para cada procesamiento:




(m) ZeroR




(n) SVM




(ñ) k-nn



(o) Árbol de decisión



(p) MLP



(q) Random Forest

Como ya hemos visto antes, no hay gran diferencia entre unos y otros. En el modelo ZeroR la **F1-Score** es 0 en los tres casos, debido a que etiqueta todas las muestras como negativas, luego no hay verdaderos positivos. En los modelos SVM, MLP, Random Forest y K-nn el procesamiento de datos 2 parece tener resultados ligeramente inferiores que los otros dos, que están muy igualados. En el árbol de decisión el procesamiento 2 tiene un mejor desempeño que el 1, pero peor que el 3. Este modelo es el que peores resultados ofrece sin considerar el ZeroR. Como podemos observar que el eje Y no llega a 0.8 como en los demás.

Al igual que en la práctica 1, el procesamiento de datos que usaría usando la información recogida en estas gráficas sería el procesamiento 3, porque en el árbol de decisión se ve que es el que mejores resultados ofrece y en el resto de modelos la diferencia con el procesamiento 1 no puedo apreciarla a simple vista.

Para crear las gráficas primero se crearon para cada modelo vector que contiene el valor de la métrica **F1-Score** de cada uno de los preprocesados:

```

v_zeror = [p1_f1[0], p2_f1[0], p3_f1[0]]
v_svm    = [p1_f1[1], p2_f1[1], p3_f1[1]]
v_knn    = [p1_f1[2], p2_f1[2], p3_f1[2]]
v_arbol  = [p1_f1[3], p2_f1[3], p3_f1[3]]
v_mlp    = [p1_f1[4], p2_f1[4], p3_f1[4]]
v_rf     = [p1_f1[5], p2_f1[5], p3_f1[5]]

```

Tras esto, para cada uno de los modelos creamos la gráfica correspondiente así:

```

fig, ax = plt.subplots()
ax.bar(["P1", "P2", "P3"], v_clf, color='blue')
ax.set_title("clf")

```

donde “clf” denota el clasificador del que recogemos los datos en la gráfica.

## 1.2. Curva ROC

Para representar la curva ROC dividimos el conjunto de datos al que se le ha aplicado el procesado 3 salvo la normalización en conjunto de entrenamiento y conjunto de validación. La división se hace de manera que el 70 % de los datos formen el conjunto de entrenamiento y el otro 30 %, el de test, conservando la proporción de elementos en cada clase tanto en el conjunto de entrenamiento como en el de validación. Esto se hace con el código:

```

X_train, X_test, y_train, y_test = model_selection.train_test_split(data, target,
    test_size=0.3, stratify=target, random_state=0)

```

Tras esto,, completamos el procesado de datos 3 usando `MinMaxScaler()` para normalizar los datos de entrenamiento y se usa estas mismas transformaciones sobre los datos de validación. A continuación, entrené los modelos con los hiperparámetros seleccionados en la práctica anterior. Podemos representar en una gráfica la curva ROC de los diferentes modelos así:


```
ax = plt.gca()
```

```

for model in [dummy_clf, svm_clf, knn_clf, tree_clf, mlp_clf, rf_clf]:
    metrics.plot_roc_curve(model, data, target, ax=ax)

```

El resultado es:




Curva ROC

Los modelos que presentan mayor métrica AUC son el Random Forest y el SVM, que son aquellos con mayor área bajo la curva ROC y los que tienen una mayor pendiente en los valores cercanos al cero. Esto implica que estos clasificadores son capaces de incrementar el número de verdaderos positivos a un ritmo mayor que el número de falsos positivos. Si usásemos esta métrica para sacar conclusiones, éstos serían los mejores modelos, mientras que el MLP es el modelo que peor comportamiento muestra, excluyendo al ZeroR. A pesar de esto, no hay excesivas diferencias entre los modelos considerados, a excepción del ZeroR.

### 1.3. Análisis de los atributos

En esta sección estudiaremos la importancia de los diferentes atributos en la clasificación. Para ello se visualizarán gráficos de barras para cada uno de los diferentes atributos y para cada una de las etiquetas, de manera que se muestre la distribución de los valores que toma dicho atributo en función de su etiqueta. También visualizaremos los diagramas de cajas, “boxplots”, de aquellos atributos donde tenga sentido.

Empezamos mostrando las gráficas correspondientes al atributo BI-RADS:



Cantidad de datos con cada etiqueta

Este atributo representa la opinión de un médico experto sobre la gravedad del tumor. Si tiene el valor “1” o “2”, el tumor es benigno, del mismo modo, si toma el valor “6” es maligno. Los valores “3”, “4” y “5” designan casos en los que no se está seguro de la severidad del tumor, pero hay cierta probabilidad de que sea maligno o benigno. Esta información la podemos comprobar en <https://es.wikipedia.org/wiki/BI-RADS>. Este atributo da mucha información sobre la naturaleza del tumor, pero dado que necesitamos la opinión de un experto para obtenerlo, no es apropiado usarlo para el aprendizaje.

Según la página <https://bigml.com/user/TotyB/gallery/dataset/509a98c6035d0706dd0001dd>, de donde hemos obtenido los datos, el 94.46 % de estos tienen BI-RADS “4” o “5”. De estos, los tumores con valor “5” son probablemente malignos. Los tumores malignos tienen más variabilidad que los benignos, dado que hay tumores malignos con valor de BI-RADS “4” o “5”, predominando el valor “5”. En el caso de los benignos, la mayoría de estos tienen la categoría de BI-RADS “4”.

Esto se ve en el diagrama de cajas de este atributo:





Diagrama de cajas de BI-RADS

Los tumores etiquetados como malignos se mueven entre el valor “4” o “5” mientras que la mayoría de los benignos toman el valor “4”.

La gráfica del atributo edad nos proporciona los siguientes resultados:



Cantidad de datos con cada etiqueta

Vemos que cuanto menor edad tiene una persona, más probable es que su tumor sea benigno. En particular, la mayoría de las personas menores de 31 años de la muestra tienen tumores benignos y gran parte de las que tienen más de 83 tienen tumores malignos. En el diagrama de cajas podemos observar que la mediana de edad de los pacientes con tumores malignos de la muestra es superior a los 60 años, mientras que la de los pacientes con tumores benignos está rondando los 50. Aunque la edad de los pacientes con tumores benignos varía entre los 18 y algo más de los 80 años, los datos entre el primer y el tercer cuartil se encuentran concentrados entre los 40 y 60. Los datos entre el primer y el tercer cuartil de los tumores malignos se encuentran entre algo más de los 50 y algo más de los 70 años.

Por consiguiente, la edad de una persona sí es un atributo relevante en la clasificación, porque aunque no podríamos estimar la severidad del tumor sabiendo sólo la edad de ésta, si una persona es muy joven podríamos esperar que su tumor sea benigno.





Diagrama de cajas de la edad

A continuación, analizaremos las gráficas del atributo Shape. La mayoría de los tumores malignos tienen una forma irregular, mientras que los benignos suelen tener una forma ovalada o redondeada. Los tumores benignos presentan mayor variabilidad en los valores que toman en este atributo que los malignos. Resulta interesante considerar este atributo para nuestro aprendizaje, ya que la distribución de los valores que toman los tumores malignos difiere bastante de la de los benignos.

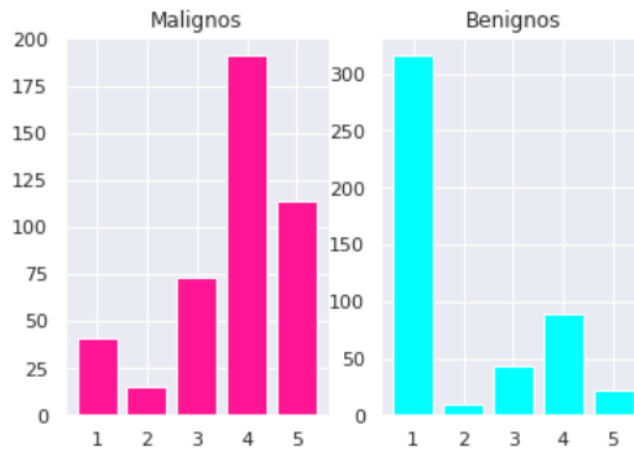


Cantidad de datos con cada etiqueta

Como el atributo Shape es cualitativo y no tiene orden, no tiene sentido dibujar un diagrama de cajas en este caso, ya que este variaría para cada asignación diferente de valores numéricos a cada posible valor del atributo, y esta asignación es totalmente aleatoria, ya que estos carecen de orden.


El siguiente atributo a analizar es Margin. Al igual que en Shape, los distintos valores que toma este atributo no tienen un orden determinado, por lo tanto no representé el diagrama de cajas de este atributo. Los tumores malignos tienen mayor variabilidad que los benignos, siendo el valor de Margin más frecuente entre estos “ill-defined” seguido del “spiculated”. Los benignos, sin embargo, suelen tener margin “circumscribed”. En la práctica 1, una vez eliminados los atributos BI-RADS y Density, vimos que este atributo era el que mayor información nos aportaba en la clasificación, dado que era el elegido en el nodo raíz del árbol de decisión. Aquí podemos comprobar que efectivamente hay una gran diferencia entre la distribución de los valores de Margin que toman los tumores malignos de los benignos, cosa que afecta favorablemente a la clasificación, permitiéndonos diferenciar una muestra maligna de una benigna con mayor facilidad.





Cantidad de datos con cada etiqueta

Por último, analizamos el atributo Density. Como ya comentamos, este atributo tiene muy poca variabilidad en la muestra y podemos comprobar que los dos diagramas de barras son muy parecidos, lo que nos incita a pensar que este atributo no aporta apenas información a la clasificación.



Cantidad de datos con cada etiqueta

En el diagrama de cajas volvemos a apreciar la poca variabilidad de este atributo, ya que cualquier valor distinto de 3 lo interpreta como outlayer. Esta razón fue la que me llevó a considerar eliminar este atributo durante el procesado de datos 3.




Diagrama de cajas de Density

## 2. Segmentación

### 2.1. Introducción

El problema que abordaremos en esta sección es agrupar accidentes obtenidos de los datos publicados por la Dirección General de Tráfico en conjuntos de accidentes con características similares. Para ello utilizaremos técnicas de clustering estudiadas en la asignatura, concretamente **K-means** y **DBSCAN**. Ambos métodos son métodos de particionamiento.

El algoritmo **K-means** necesita como parámetro el número de clústers deseado y va clasificando las diferentes instancias en el clúster cuyo centroide sea el más cercano a ésta. Es un método iterativo que recalcula el centroide en cada iteración y repite el proceso de clasificación de las instancias. Termina cuando en una iteración ninguna instancia cambia de clúster. El algoritmo siempre converge.

El algoritmo **DBSCAN** depende de los parámetros *epsilon* y *min\_samples*. El primero indica la distancia máxima a la que se considera que dos puntos son directamente alcanzables. Para que un punto sea un punto núcleo necesita que haya al menos *min\_samples* a distancia menor que *epsilon* de él. A partir de ahí, un punto será alcanzable si existe una secuencia de puntos  $p_1, \dots, p_n$  tales que  $p_{i+1}$  es directamente alcanzable desde  $p_i$ . Cada punto núcleo forma un clúster formado por todos aquellos puntos alcanzables desde él. A los puntos que no pertenecen a ningún clúster se les asigna el clúster  $-1$ .

Los atributos en los que nos basamos para hacer la segmentación son:

- **TOT\_VICTIMAS**: Total de víctimas
- **TOT\_MUERTOS**: Total de muertos
- **TOT\_HERIDOS\_GRAVES**: Total de heridos graves.
- **TOT\_HERIDOS\_LEVES**: Total de heridos leves.
- **TOT\_VEHICULOS\_IMPLICADOS**: Total de vehículos involucrados en el accidente.

Las métricas que usaremos para la estimar la bondad del ajuste son el coeficiente Silhouette y el índice Calinski-Harabasz.

El coeficiente Silhouette mide como de similares son los elementos del mismo clúster comparado con los elementos de otro clúster. Este coeficiente es la media de los  $s(i)$ , con

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

donde  $b(i)$  es la mínima distancia del elemento  $i$  a otro clúster y  $a(i)$  es la distancia media del elemento al resto de instancias de su clúster. Cuanto mayor sea este coeficiente, mejor es el rendimiento del modelo.

El índice Calinski-Harabasz mide la razón entre la dispersión interclústers y la dispersión intraclústers. El agrupamiento será mejor cuanto mayor sea este índice.

Para la elección de hiperparámetros, elegiremos aquellos que maximicen el índice Calinski-Harabasz, que utiliza todas las muestras para su cálculo y dado que usamos los mismos datos en todas las iteraciones, que su valor no esté normalizado no afecta en la interpretación del resultado.

Antes de realizar el análisis ejecutando los algoritmos de clusterig normalizamos los datos con la función **MinMaxScaler**, cuyo comportamiento es el mismo que la función **norm** de **pract2\_utils**, por lo que es correcto usar **denorm** con los datos normalizados para deshacer esta operación (como hacemos para representar los centroides).

## 2.2. Caso de estudio 1: Choque frontal en carreteras convencionales

Estudiaremos las propiedades de los choques frontal en carreteras convencionales que, según el libro [Manual del alumno. Permiso B](#), es el caso de accidente con más víctimas mortales. Por tanto estudiaremos las diferentes características de dichos accidentes mediante clustering, agrupando los accidentes de esta categoría y viendo las propiedades de cada uno de esos grupos. Para ello usaremos los algoritmos K-Means y DBSCAN.

### 2.2.1. K-means

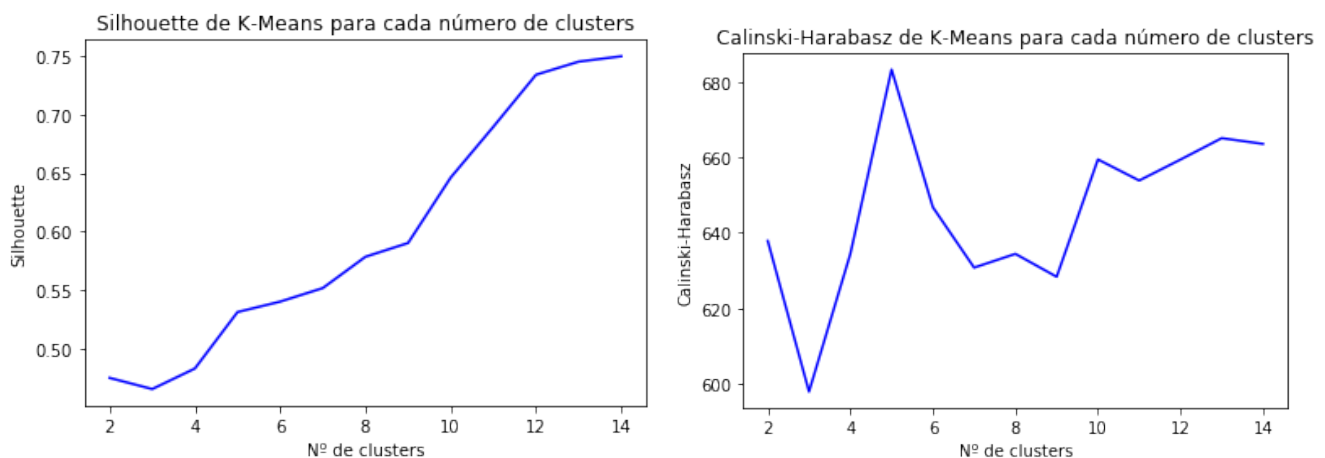
El algoritmo **K-means** tiene como parámetro el número de clústers a considerar. Para elegir el mejor valor de éste, ejecuté el algoritmo con un número de clústers comprendido entre 2 y 14. Los resultados de las métricas son:

Nº de clústers	Silhouette	Calinski-Harabasz
2	0.4755151052183165	637.8831140088855
3	0.46599969633063965	597.9798532808658
4	0.48348908673333896	634.4016355078425
5	0.531569055229591	683.2263367508311
6	0.5404576589330072	646.8004817570682
7	0.5519986909803548	630.8036708742871
8	0.5786471085948179	634.4445453990445
9	0.5903779353773022	628.3756258948337
10	0.6461326222918197	659.4342926638305
11	0.6893747693555886	653.852874658656
12	0.7336714808160643	659.3965542394021
13	0.744841516853055	665.0690582901761
14	0.749410469848095	663.5502144820157

Para facilitar la comprensión de la tabla, visualizamos la información que contiene en las siguientes gráficas, que se realizan utilizando la función **grafica**, cuyo código es:

```
def grafica(data, label, title, xlab, ylab):  
    plt.plot(data, label, c='b')  
    plt.title(title)  
    plt.xlabel(xlab)  
    plt.ylabel(ylabel)  
  
    plt.show()
```


Obtenemos el siguiente resultado:



Gráficas con el valor de las métricas en función del número de clústers

Vemos que el coeficiente Calinski-Harabasz alcanza un máximo cuando se consideran 5 clústers, por lo que elegiremos este valor para dicho hiperparámetro.

El resultado de la segmentación es la división del conjunto de accidentes considerados en 5 conjuntos con las siguiente distribución:




Vemos que el 51.24 % de los accidentes pertenecen al clúster 0. El siguiente clúster más grande, el 2, posee el 18.65 % de éstos y el 4 posee el 14.51 %. Los clústers con menos elementos son el 1 y el 3 con el 8.08 % y el 7.53 %, respectivamente. Veremos después las características de cada uno de los clústers.

Los valores de las métricas para este modelo son:

Silhouette	Calinski-Harabasz
0.531569055229591	683.2263367508311

Los centroides de los diferentes clusters son:



El clúster 0, que es aquel con más instancias, tiene como centro un accidente con 2.059 vehículos implicados, del que 1.387 personas han sido heridos leves, pero sin muertos ni heridos graves. Es el clúster cuyo centro tiene un menor número de víctimas, y las que tiene son heridos leves.

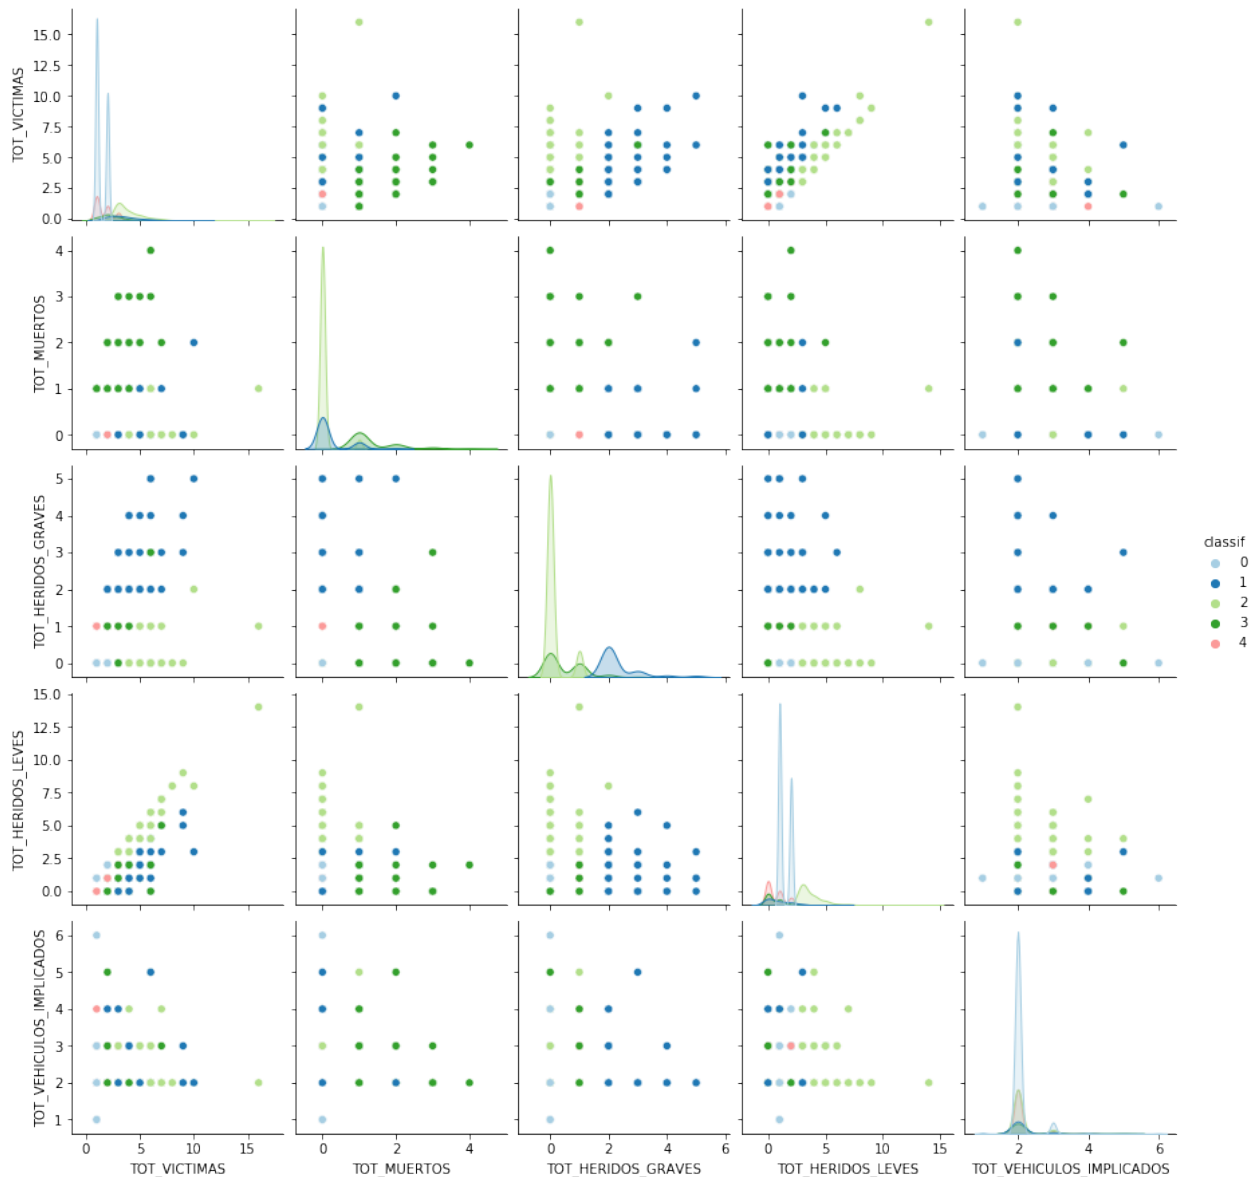
El clúster 1 tiene como centro un accidente con 3,573 víctimas, en el que 2,342 son heridos graves, 1.043 son heridos leves y 0.188 son muertos. Hubo 2.162 vehículos implicados. Es el clúster con mayor número de heridos graves de media, pero es el segundo clúster con menos instancias.

El clúster 2 tiene como centro un accidente con 3.981 víctimas, la mayoría heridos leves. Tiene de media más víctimas y heridos leves que el resto, pero es el segundo con menos heridos graves. Como en el resto de clústers, los vehículos involucrados están alrededor de 2.

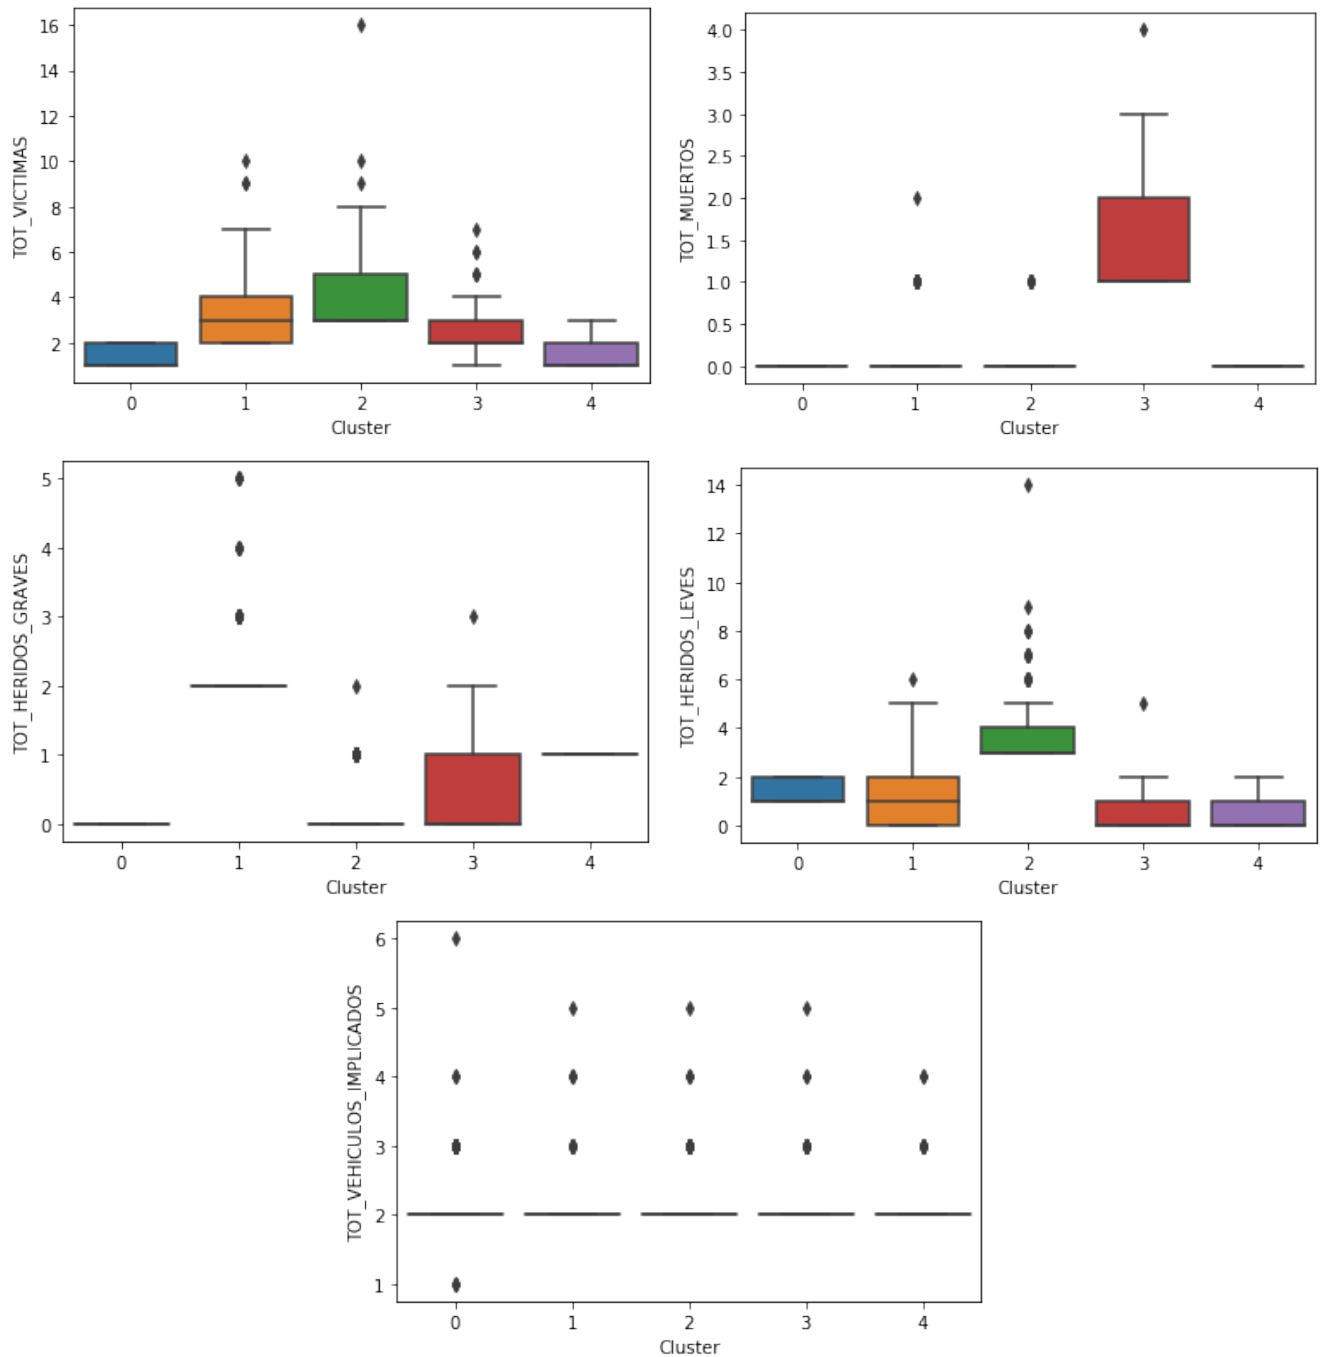
El clúster 3 tiene como centro un accidente con 2.3850 víctimas. Tiene de media más muertos que el resto, 1.358 muertos. También tiene 0.477 heridos graves y 0.55 heridos leves. Es el clúster con menos instancias de los cinco.

El clúster 4 tiene como centro un accidente con 1.648 víctimas, pero ningún muerto. Es el segundo clúster con más heridos graves y el segundo con menos heridos leves. Como en el resto de clústers, el número de vehículos implicados está entorno a dos.

Las diferencias entre los distintos clústers pueden visualizarse con `pairplot`:



Podemos corroborar lo que vimos con los centroides, que todos los clústers suelen tener entorno a 2 vehículos implicados. En el atributo TOT\_HERIDOS\_GRAVES nos ayuda a discernir el clúster 1 de los clusters 2 y 3. El atributo TOT\_HERIDOS\_LEVES diferencia los clústers 4, 0 y 2. Para ver estas diferencias de manera más detallada podemos usar boxplot:



Diagramas de cajas

En la siguiente tabla mostramos el rango de valores más representativo de cada cluster:

Nº del clúster	Víctimas	Muertos	Heridos graves	Heridos leves	Vehículos implicados
0	1-2	0	0	1-2	2
1	2-7	0	2	0-5	2
2	3-8	0	0	3-5	2
3	0-4	1-3	0-2	1-2	2
4	0-3	0	1	1-2	2

Salvo outliers, todos los clúster están compuestos por accidentes con dos vehículos implicados.

El clúster 0 está compuesto por accidentes sin muertos ni heridos graves, y entre uno y dos heridos leves. Es aquel con más datos y cuyos accidentes son menos graves.

El clúster 1 está formado principalmente por accidentes con dos heridos graves y entre cero y cinco heridos leves. Es aquel con mayor variabilidad de heridos leves.

El clúster 2 está compuesto mayoritariamente por accidentes sin muertos ni heridos graves y entre tres y cinco heridos leves. Es aquel con más víctimas, pero todas ellas son heridos leves.

El clúster 3 es el único cluster, salvo outliers, en cuyos accidentes hay muertos, entre uno y cinco concretamente. hay entre cero y dos heridos graves y entre uno y dos leves.

El clúster 4 se compone de accidentes con un herido grave y entre uno y dos leves.


Vemos que el atributo `TOT_VEHICULOS_IMPLICADOS` no es muy informativo, ya que todos los clústers se componen mayoritariamente de accidentes donde sólo hay dos vehículos implicados. El atributo `TOT_MUERTOS` sólo ayuda a diferenciar un clúster del resto. Los atributos que más información dan sobre la composición de cada clúster son `TOT_HERIDOS_LEVES` y `TOT_HERIDOS_GRAVES`.

### 2.2.2. DBSCAN

El algoritmo DBSCAN tiene como parámetro la distancia a la que consideramos que dos puntos son directamente alcanzables, *epsilon*. Consideré que un clúster tenía que estar constituido por 10 puntos mínimo. Para elegir el mejor valor de *epsilon*, ejecuté el algoritmo con diez valores de *epsilon* equidistantes entre 0.02 y 0.2, ambos incluidos. Elegí valores inferiores a 0.2 porque con valores mayores de *epsilon* el algoritmo sólo creaba un clúster diferente al clúster -1. Los resultados de las métricas son:


Epsilon	Silhouette	Calinski-Harabasz
0.02	0.7895289623335725	114.4553269039885
0.04	0.7895289623335725	114.4553269039885
0.06	0.7895289623335725	114.4553269039885
0.08	0.7895289623335725	114.4553269039885
0.1	0.4869805568764864	165.50098317272966
0.12	0.4869805568764862	165.50098317272966
0.14	0.4869805568764861	165.50098317272966
0.16	0.4869805568764864	165.50098317272966
0.18	0.4869805568764862	165.50098317272966
0.2	0.5005453962094687	185.66574970475563

Para facilitar la comprensión de la tabla, visualizamos la información que contiene en las siguientes gráficas:




Gráficas con el valor de las métricas en función del número de clústers

Para elegir el valor de *epsilon* apropiado, visualizamos los clústers formados con *epsilon*= 0.08 y *epsilon*= 0.1:



Gráficas con *epsilon* = 0.08 y *epsilon*=0.1 respectivamente

Elegimos el valor de *epsilon*= 0.1, dado que con *epsilon*=0.08 trece de los diecisiete clústers formados tienen menos de 60 datos. Además, hay casi el doble de accidentes componiendo el clúster -1, es decir, hay casi el doble de elementos que no han podido asignarse a ninguno de los otros clústers y no tienen un clúster que los represente. Por tanto, la distribución de los clústers con el parámetro ajustado es:



Clústers

Vemos que se han formado diez clústers, siendo el clúster con identificador -1 aquel compuesto por todos los datos que no encajaban en ninguno de los otros nueve. Hay 100 datos pertenecientes a este clúster, es decir, el 6.91 % de




los datos no se clasifica correctamente. El clúster cero tiene más instancias que el resto, un total de 908, seguido del clúster dos, que tiene 221. Los clústers 1 y 3 tienen 65 y 51 instancias respectivamente, y el resto de clústers no superan las 41 instancias.

Los valores de las métricas para este modelo son:

Silhouette	Calinski-Harabasz
0.4869805568764864	165.50098317272966

Los centroides de los diferentes clusters son:



El clúster 0 tiene como centro un accidente con 2 vehículos implicados, en el que 1.922 personas han sido heridos leves, pero sin muertos ni heridos graves. Este clúster es aquel con mayor número de instancias, conteniendo el 62.71 % de instancias.

El clúster 1 tiene como centro un accidente con 2.969 víctimas, dos heridos graves y 0.969 heridos leves, sin muertos. Dos vehículos se han visto involucrados.

El clúster 2 tiene como centro un accidente con 1.973 víctima, un herido grave y 0.973 heridos leves, y dos vehículos implicados. Es el segundo clúster con mayor número de accidentes.

El clúster 3 tiene como centro un accidente con 1.585 víctimas, de las cuales una es un muerto y 0.585, heridos leves. Hubo dos vehículos implicados.

El clúster 4 tiene como centro un accidente con dos vehículos implicados, que tiene como resultado 2.52 víctimas, un muerto, un herido grave y 0.52 heridos leves.

El clúster 5 tiene como centro un accidente con 1.961 víctimas, todas ellas heridos leves. Hubo tres vehículos implicados.

El clúster 6 tiene como centro un accidente con 3.273 víctimas, tres heridas gravemente y 0.273 heridos leves. Hubo dos vehículos implicados en este accidente. Es el clúster con menos instancias, sólo 11.

El clúster 7 tiene como centro un accidente con 2.571 víctimas, un herido grave y el resto heridos leves. Hubo tres vehículos implicados.

El clúster 8 tiene como centro un accidente con un muerto, dos heridos graves y 0.833 heridos leves. Hubo dos vehículos implicados. Es el segundo clúster con menor número de instancias.

El centro del clúster -1 no aporta mucha información, dado que está compuesto por todos aquellos datos que no encajan con el resto de clúster, por lo tanto hay una gran variabilidad entre los atributos de los accidentes asignados a este clúster.

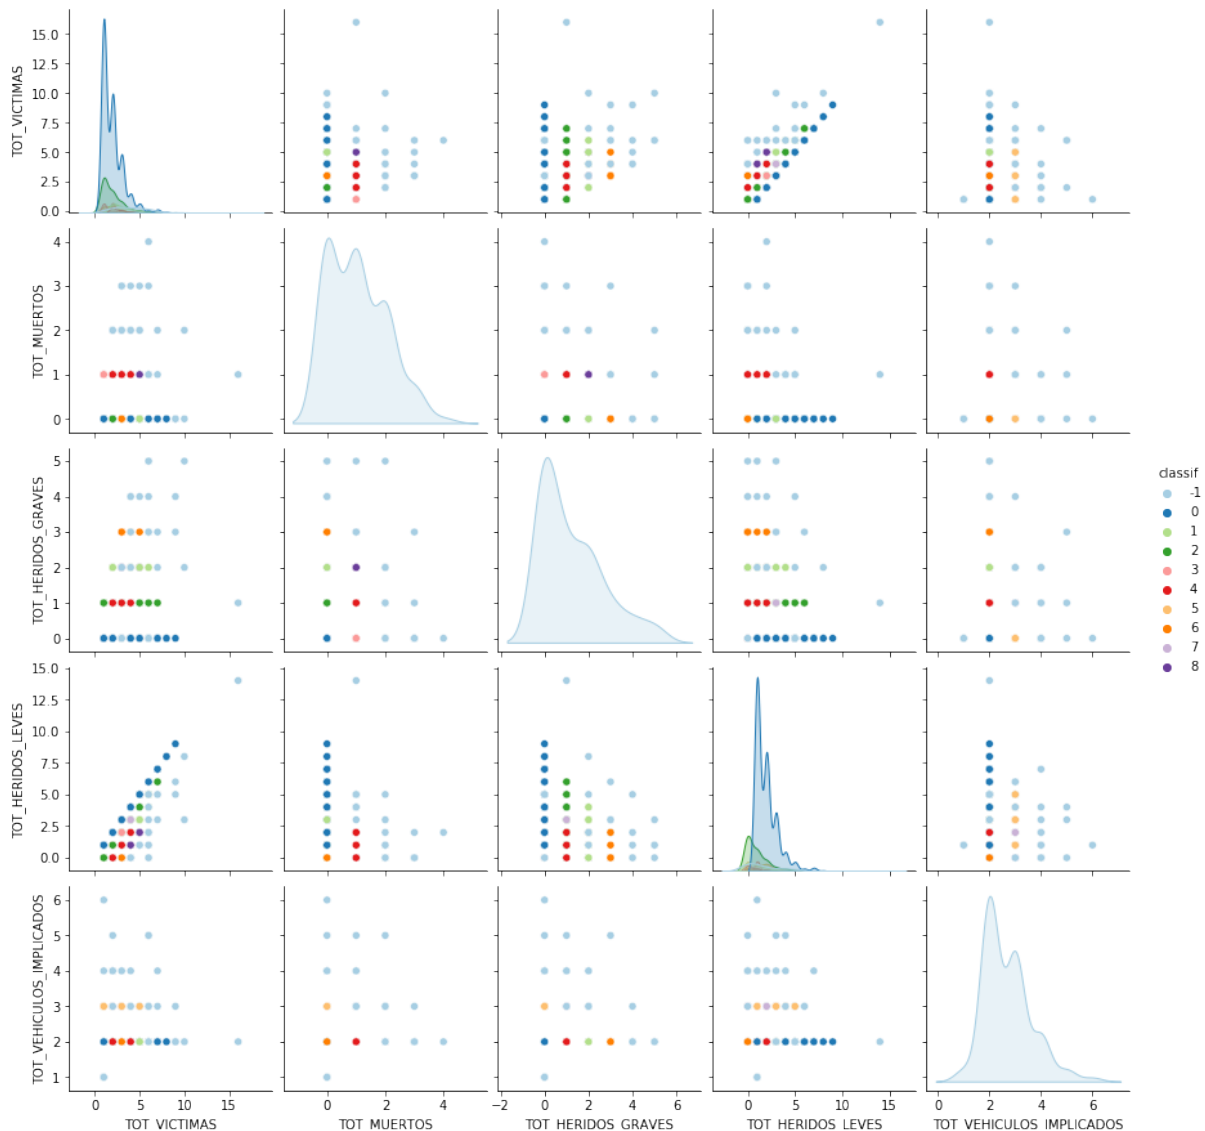
Para visualizar los centroides se usó el siguiente código:

```
datos_cen = caso1.copy()
datos_cen.columns = atributos
datos_cen['Cluster'] = results.labels_

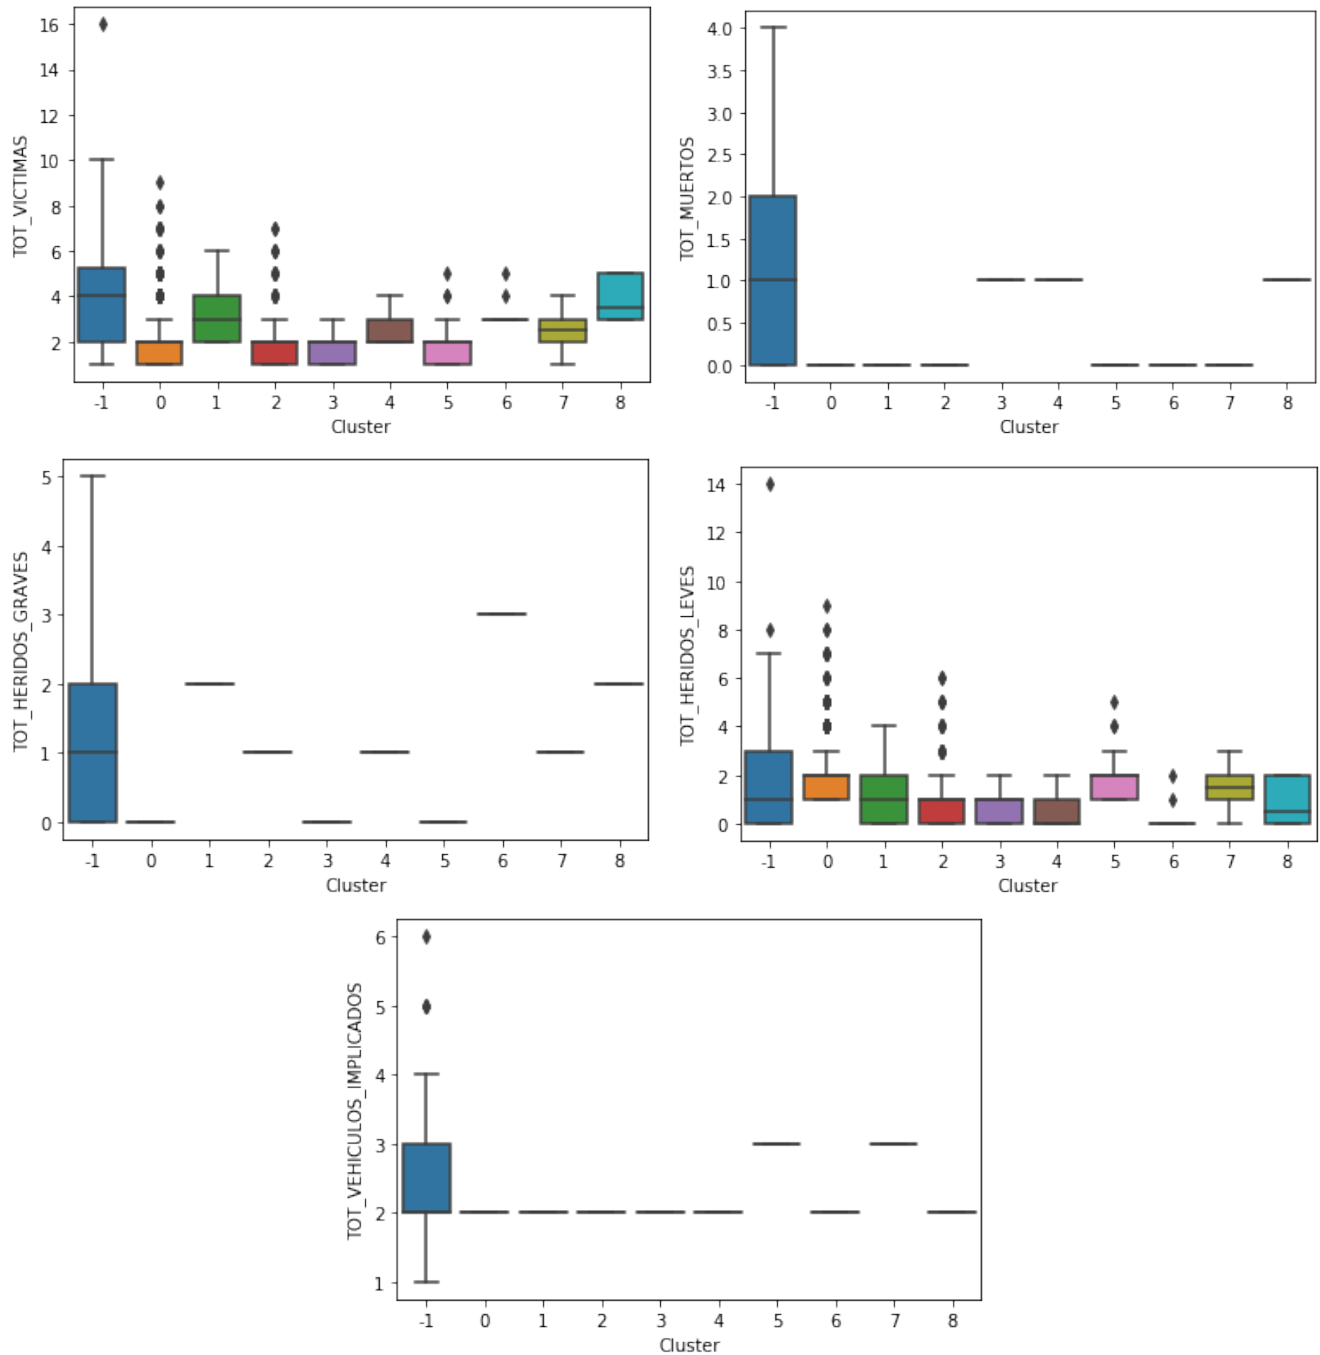
centroids = datos_cen.groupby('Cluster').mean()
visualize_centroids_dbscan(centroids, np.array(caso1), atributos)
```

Donde la función `visualize_centroids_dbscan` es análoga a la función `visualize_centroids`, pero no aplica `denorm`, ya que los centroides no se le pasan normalizados.

Como con K-Mean, utilicé `pairplot` con la esperanza de ver diferencias entre los distintos clústers. Vemos que los dos atributos que más ayudan a diferenciar los distintos clústers son `TOT_VICTIMAS` y `TOT_HERIDOS_GRAVES`.



Representamos pues diagramas de cajas para poder ver mejor la variabilidad de los diferentes atributos en cada clúster y diferenciarlos así.



Diagramas de cajas

El clúster -1 es aquel con más variabilidad en todos los atributos por estar compuesto por todos aquellos accidentes que no encajaban en el resto de clústers, es por eso que sus atributos tienen más variabilidad que en el resto de clústers.

En la siguiente tabla mostramos el rango de valores más representativo de cada cluster:

Nº del clúster	Víctimas	Muertos	Heridos graves	Heridos leves	Vehículos implicados
0	1-3	0	0	1-3	2
1	2-6	0	2	0-4	2
2	1-3	0	1	0-2	2
3	1-3	1	0	0-2	2
4	2-4	1	1	0-2	2
5	1-3	0	0	1-3	3
6	3	0	3	0	2
7	1-4	0	1	0-3	3
8	3-5	1	2	0-2	2

El clúster 0 está formado por accidentes sin heridos graves ni muertos, donde la mayoría de ellos tienen entre 1 y 3 heridos leves. En ellos hay dos vehículos implicados.

El clúster 1 está formado por accidentes con dos vehículos implicados, sin muertos, dos heridos graves y entre 0 y 4 heridos leves, estando la mediana en un herido leve.

El clúster 2 está compuesto por accidentes sin muertos, un herido grave y entre 0 y 2 heridos leves. Se vieron involucrados dos vehículos.

El clúster 3 está compuesto por accidentes con dos vehículos implicados, un muerto, entre 0 y 2 heridos leves y sin heridos graves.

El clúster 4 está compuesto por accidentes con dos vehículos implicados, un muerto, un herido grave y entre 0 y 2 heridos leves.

El clúster 5 está formado por accidentes con entre 1 y 3 víctimas, todas ellas heridos leves. Hubo tres vehículos implicados. La diferencia de este clúster con el clúster cero es el número de vehículos implicados.

El clúster 6 está compuesto por accidentes con 3 víctimas, todas ellas heridos graves. Hubo dos vehículos implicados.

El clúster 7 está compuesto por accidentes con entre 1 y 4 víctimas, un herido grave y entre 0 y 3 heridos leves, y con tres vehículos implicados.

El clúster 8 está formado por accidentes con un muerto, dos heridos graves y entre 0 y dos leves. Hubo dos vehículos implicados.

Vemos que los atributos TOT\_MUERTOS, TOT\_HERIDOS\_GRAVES y TOT\_VEHICULOS\_IMPLICADOS apenas tienen variabilidad dentro de cada clúster.

### 2.2.3. Comparación de los algoritmos

Los resultados de los algoritmos considerados son:

Algoritmo	Silhouette	Calinski-Harabasz	Nº de clústers
K-Means	0.531569055229591	683.2263367508311	5
DBSCAN	0.4869805568764864	165.50098317272966	10

Vemos que el algoritmo K-Means obtiene un valor de la métrica Calinski-Harabasz más de cuatro veces superior del valor que obtiene DBSCAN con esa misma métrica. También obtiene un mayor valor en la métrica Silhouette. Por tanto, podríamos decir que el algoritmo Kmeans tiene un mejor desempeño que el DBSCAN en este caso.

El algoritmo DBSCAN divide los accidentes en más clústers que el Kmeans, y la variabilidad de los atributos en cada clústers es menor. Además la distribución de clústers es menos homogénea, habiendo cinco clústers con menos de 50 instancias.


El algoritmo Kmeans tiene por tanto mejor comportamiento que el DBSCAN, consiguiendo mejor valor en la métrica Calinski-Harabasz, y consigue agrupar los accidentes en cinco clusters claramente diferenciados, aumentando ligeramente la variabilidad de cada atributo en la cluster.

#### **2.2.4. Interpretación de la segmentación**

En la mayoría de accidentes hay dos vehículos implicados, por lo que el atributo `TOT_VEHICULOS_IMPLICADOS` no aporta mucha información. El atributo `TOT_VICTIMAS` tampoco es muy relevante, puesto que puede calcularse a partir de `TOT_MUERTOS`, `TOT_HERIDOS_GRAVES` y `TOT_HERIDOS_LEVES`. El atributo `TOT_MUERTOS` sirve para diferenciar uno o tres clúster en cada uno de los modelos considerados del resto, y el resto de clústers se diferencian entre sí por los atributos `TOT_HERIDOS_GRAVES` y `TOT_HERIDOS_LEVES`, por lo que estos son los atributos dos más relevantes para el agrupamiento.

### 2.3. Caso 2: Fin de semana con densidad de circulación densa

Nos preguntamos si durante los fines de semana hay un mayor número de víctimas que el resto de la semana, por lo que visualizamos el diagrama de cajas del atributo TOT\_VICTIMAS respecto al día de la semana.



Diagramas de cajas



Obtenemos que efectivamente la variabilidad de este atributo es mayor en el fin de semana que en el resto de días, por lo que decidimos elegir como nuestro segundo caso los accidentes ocurridos los viernes, sábados o domingos. Además, elegí aquellos accidentes en los que la densidad de circulación es “DENSE”, que representarán los días en los que mucha gente se desplace para disfrutar del fin de semana, como festividades.

#### 2.3.1. K-means

Para elegir el mejor valor para el número de clústers que considera el algoritmo K-means, ejecuté el algoritmo con un número de clústers comprendido entre 2 y 14. Los resultados de las métricas son:




Nº de clústers	Silhouette	Calinski-Harabasz
2	0.5370884902834917	680.6474578600636
3	0.5022253639905714	691.2087946486065
4	0.5253455054070136	731.3590806547992
5	0.494182230718928	794.2278720981091
6	0.5384826599151725	904.0949725499044
7	0.601310808513732	925.9700253681594
8	0.622859268196415	942.1012174830314
9	0.7013609213343277	963.5793862878563
10	0.7221502954295131	954.6141788919715
11	0.7266476702162132	964.5578901852715
12	0.7385815169799497	996.4201247190041
13	0.7445925945766767	1032.2367917798642
14	0.7557938837992468	1058.1110463372995

Para facilitar la comprensión de la tabla, visualizamos la información que contiene en las siguientes gráficas:



Gráficas con el valor de las métricas en función del número de clústers


Vemos que ambas métricas aumentan cuanto mayor es el número de clústers considerados, pero un número de clústers muy alto puede tener con resultado que el modelo esté más sobreajustado. Podemos comprobar esto en las siguientes gráficas:



Clústers

Con 13 clústers hay 6 clústers con menos de 50 accidentes, con 9 clúster solo hay 2 con menos de 50 accidentes y con 5 clústers solo uno. Con ánimo de tener una métrica Calinski-Harabasz alta pero sin tener clústers con pocas instancias, que pueden ser causa del sobreajuste del modelo, utilizaremos nueve clústers.

El resultado de la segmentación es la división del conjunto de accidentes considerados en 9 conjuntos con las siguiente distribución:




Clústers

El clúster con más accidentes es el 2, con 415 accidentes, seguido del clúster 6, que posee 240. Los clúster con menos accidentes son el 3 con 17 y el 4 con 48.

Los valores de las métricas para este modelo son:

Silhouette	Calinski-Harabasz
0.7013609213343277	963.5793862878563

Los centroides de los diferentes clusters son:



El clúster 0 tiene como centro un accidente con 3.244 vehículos implicados, en el que 0.993 personas han sido heridos leves y 0.007 heridos graves, pero sin muertos.

El clúster 1 tiene como centro un accidente con 3.312 víctimas, 3.262 heridos leves y 0.050 heridos graves, sin muertos. Se han visto involucrados 2.404 vehículos.

El clúster 2 tiene como centro un accidente con 1 víctima, herida levemente, y dos vehículos implicados.

El clúster 3 tiene como centro un accidente con 1.941 vehículos implicados, en el que 1.294 personas han sido heridos leves, 0.588 heridos graves y un muerto.

El clúster 4 tiene como centro un accidente con 5.771 víctimas, 5.604 heridos leves y 0.167 heridos graves, sin muertos. Se han visto involucrados 3.125 vehículos.

El clúster 5 tiene como centro un accidente con 1.372 víctimas, 0.271 heridos leves y 1.101 heridos graves, sin muertos. Se han visto involucrados 1.636 vehículos.

El clúster 6 tiene como centro un accidente con 2 víctimas, heridas levemente, sin heridos graves ni muertos. Se han visto involucrados 2.112 vehículos.

El clúster 7 tiene como centro un accidente con 4.773 vehículos implicados, en el que 2.32 personas han sido heridos leves, 0.013 heridos graves y sin muertos.

El clúster 8 tiene como centro un accidente con una víctima, herida levemente, sin heridos graves ni muertos y un sólo vehículo implicado.

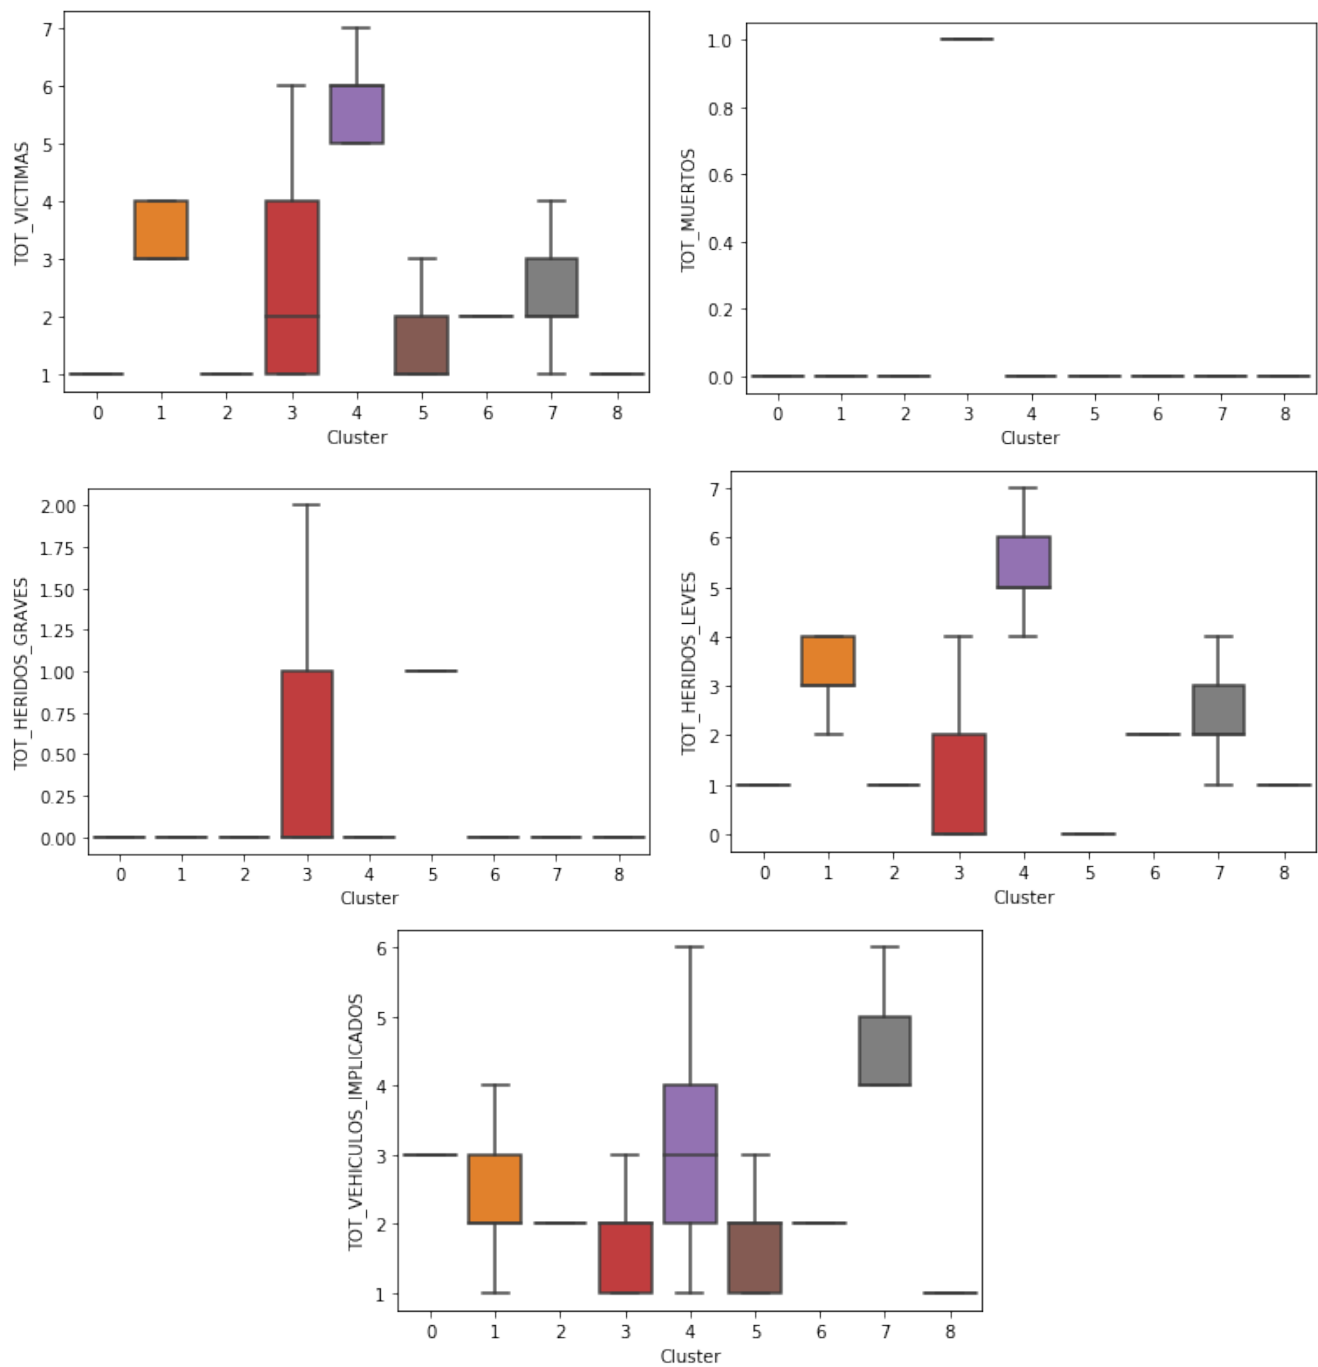
Utilizamos la función `pairplot` para ver las diferencias entre los distintos clústers:





Los atributos TOT\_VICTIMAS y TOT\_VEHICULOS\_IMPLICADOS son aquellos que más ayudan a discernir los diferentes clústers. El atributo TOT\_HERIDOS\_LEVES diferencia los clústers 5, 0 y 7 y 1, y el atributo TOT\_HERIDOS\_GRAVES distingue el clúster 5 de los demás. El atributo TOT\_MUERTOS no aporta tanta información, ya que su media vale 0 en la mayoría de los clústers.

Visualizamos a continuación los diagramas de cajas de los diferentes atributos en cada clúster.



Diagramas de cajas

En la siguiente tabla mostramos el rango de valores más representativo de cada cluster:

Nº del clúster	Víctimas	Muertos	Heridos graves	Heridos leves	Vehículos implicados
0	1	0	0	1	3
1	3-4	0	0	3-4	1-4
2	1	0	0	1	2
3	1-6	1	0-2	0-4	1-3
4	5-7	0	0	4-7	1-6
5	1-3	0	1	0	1-3
6	2	0	0	2	2
7	1-4	0	0	1-4	4-6
8	1	0	0	1	1

El clúster 0 está compuesto por accidentes con 3 vehículos implicados sin muertos ni heridos graves y un herido leve.

El clúster 1 está formado por accidentes con entre tres y cuatro heridos leves, sin muertos o heridos graves. Se vieron implicados entre uno y cuatro vehículos.

El clúster 2 está compuesto por accidentes sin muertos ni heridos graves y un herido leve. Se diferencia del clúster 0 por tener 2 vehículos implicados en lugar de tres. Es aquel con más muestras.

El clúster 3 es el único cluste en cuyos accidentes hay muertos. Hay un muerto concretamente. También hay entre cero y dos heridos graves y entre cero y cuatro leves. Se vieron involucrados entre uno y tres vehículos. Es el clúster con menos muestras.

El cúster 4 se compone de accidentes con entre cuatro y siete víctimas, todas ellas heridos leves. Puede haber entre uno y seis vehículos implicados.

El cúster 5 se compone de accidentes con entre uno y tres vehículos implicados y entre una y tres víctimas.

El cúster 6 se compone de accidentes con dos víctimas, todos ellos heridos leves, y dos vehículos implicados. Es el segundo clúster con mayor número de muestras.

El cúster 7 se compone de accidentes con entre una y cuatro víctimas, todas ellas heridos leves. Puede haber entre cuatro y seis vehículos implicados.

El clúster 8 está compuesto por accidentes sin muertos ni heridos graves y un herido leve. Se diferencia del clúster 0 y 2 por tener un solo vehículo implicado en lugar de dos o tres. Tiene menos muestras que el clúster dos, pero más que el cero.


En la mayoría de accidentes no hay muertos, por lo que el atributo `TOT_MUERTOS` sólo ayuda a diferenciar el clúster 3, compuesto por 17 instancias, del resto. El atributo `TOT_HERIDOS_GRAVES` sólo difiere de cero en los clúster 3 y 5. El resto de clústers se diferencian entre sí por los atributos `TOT_HERIDOS_LEVES` y `TOT_VEHICULOS_IMPLICADOS`, por lo que estos son los atributos dos más relevantes para el agrupamiento.

### 2.3.2. DBSCAN

Al igual que en el caso 1, estimamos el valor del parámetro *epsilon*, la distancia a la que consideramos que dos puntos son directamente alcanzables. El valor de *min\_samples* considerado sigue siendo cinco. Ejecuté el algoritmo con diez valores de *epsilon* equidistantes entre 0.02 y 0.2, ambos incluidos. Los resultados de las métricas son:


Epsilon	Silhouette	Calinski-Harabasz
0.02	0.82892254556956	116.97236922937577
0.04	0.8289225455695599	116.97236922937577
0.06	0.8289225455695599	116.97236922937577
0.08	0.82892254556956	116.97236922937577
0.1	0.82892254556956	116.97236922937577
0.12	0.8289225455695599	116.97236922937577
0.14	0.4536119566421056	220.24625024938823
0.16	0.4045951263790732	200.4202941262233
0.18	0.4045951263790732	200.4202941262233
0.2	0.40701069566142584	172.58676418042137

Para facilitar la comprensión de la tabla, visualizamos la información que contiene en las siguientes gráficas:



Gráficas con el valor de las métricas en función del número de clústers

Seleccioné el valor de  $\epsilon = 0.14$  porque es en el que se maximiza la métrica Calinski-Harabasz. La métrica Silhouette no utiliza todas las muestras para su cálculo y depende entonces de las muestras seleccionadas, por lo que decidí anteponer la maximización de la métrica Calinski-Harabasz a la de ésta. Los clústers formados quedan así:



Gráficas con el valor de las métricas en función del número de clústers


Vemos que se han formado 9 cluster, siendo el clúster con identificador  $-1$  aquel compuesto por todos los datos que no encajaban en ninguno de los otros 8. Hay 61 datos pertenecientes a este clúster, es decir, el 4.41 % de los datos no se clasifica correctamente. El clúster con más instancias es el 0, que cuenta con 740, seguido del clúster 3, con

273. Los clústers que superan las 100 instancias son el clúster 0, el 3 y el 5. El clúster 2 tiene 98, y el resto menos de 65.

Los valores de las métricas para este modelo son:

Silhouette	Calinski-Harabasz
0.4536119566421056	220.24625024938823

Los centroides de los diferentes clusters son:



El clúster 0 tiene como centro un accidente con 2.012 vehículos implicados, en el que una personas han sido herida levemente, pero sin muertos ni heridos graves.

El clúster 1 tiene como centro un accidente con dos víctimas, una herida leve y otra herida grave, sin muertos. Se han visto involucrados 1.947 vehículos.

El clúster 2 tiene como centro un accidente con 1 víctima, herida gravemente, y 1.596 vehículos implicados.

El clúster 3 tiene como centro un accidente con dos víctimas, ambas heridos leves. Hubo 2.370 vehículos implicados.

El clúster 4 tiene como centro un accidente con 6 víctimas, todas ellas heridos leves, y 2.824 vehículos implicados.

El clúster 5 tiene como centro un accidente con 3 víctimas, todas ellas heridos leves, y 2.726 vehículos implicados.

El clúster 6 tiene como centro un accidente con 2.886 vehículos implicados en que que 4 personas resultaron heridas levemente.

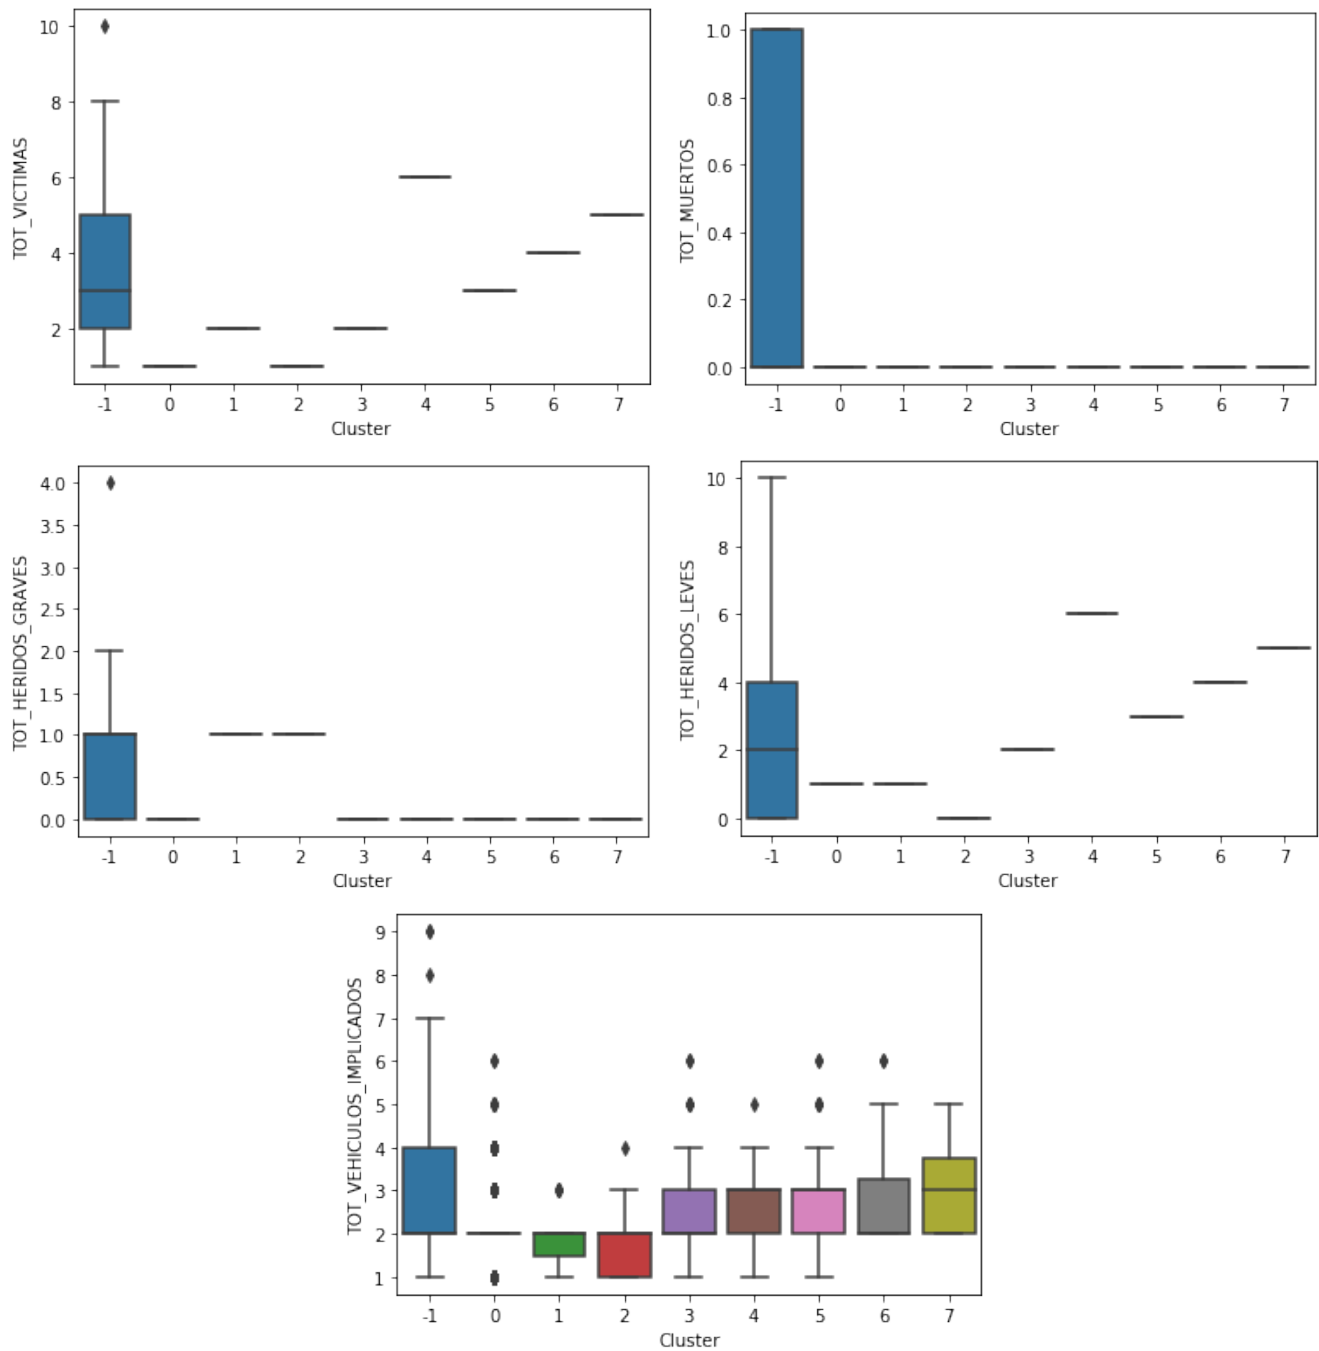
El clúster 7 tiene como centro un accidente con 5 víctimas, las cinco heridas leves. Hubo tres vehículos implicados.

Vemos que el atributo TOT\_MUERTOS tiene media cero en todos los cústers, y sólo dos de ellos tienen de media el atributo TOT\_HERIDOS\_GRAVES distinto de cero. Los atributos que más varían entre los cústers son TOT\_HERIDOS\_LEVES y TOT\_VEHICULOS\_IMPLICADOS.

Como con K-Mean, utilicé **pairplot** con la esperanza de ver diferencias entre los distintos clústers, pero los resultados no son los esperados y sólo podemos sacar información a partir del atributo TOT\_VEHICULOS\_IMPLICADOS, que, como veremos a continuación en el diagrama de cajas, es el único atributo con variabilidad en los clústers.



Representamos pues diagramas de cajas para poder ver mejor la variabilidad de los diferentes atributos en cada clúster y diferenciarlos así.



Diagramas de cajas

El clúster -1 es aquel con más variabilidad en todos los atributos por estar compuesto por todos aquellos accidentes que no encajaban en el resto de clústers. El resto de clústers tienen poca variabilidad en la mayoría de los atributos, a excepción del **TOT\_VEHICULOS\_IMPLICADOS**. El atributo **TOT\_MUERTOS** no aporta información en el agrupamiento, ya que ninguno de los clústers formados contiene accidentes con muertos, todos estos accidentes son colocados en el clúster -1, junto con el resto de accidentes que no es capaz de clasificar correctamente.

En la siguiente tabla mostramos el rango de valores más representativo de cada clúster:

Nº del clúster	Víctimas	Muertos	Heridos graves	Heridos leves	Vehículos implicados
0	1	0	0	1	2
1	2	0	1	1	1-2
2	1	0	1	0	1-3
3	2	0	0	2	1-4
4	6	0	0	6	1-4
5	3	0	0	3	1-4
6	4	0	0	4	2-5
7	5	0	0	5	2-5

Como el único atributo con variabilidad es `TOT_VEHICULOS_IMPLICADOS`, lo único que diferencia a cada instancia de un clúster del centro de éste es el número de vehículos involucrados en dicho accidente. Este atributo junto con `TOT_HERIDOS_LEVES` es el que más ayuda a la diferenciación de los distintos clústers entre sí.

### 2.3.3. Comparación de los algoritmos

Los resultados de los algoritmos considerados son:

Algoritmo	Silhouette	Calinski-Harabasz	Nº de clústers
Kmeans	0.7013609213343277	963.5793862878563	9
DBSCAN	0.4536119566421056	220.24625024938823	9

Aunque ambos algoritmos crean el mismo número de clústers, el algoritmo K-means tiene un mejor desempeño que el DBSCAN. El K-means consigue clústers cuyos atributos tienen mayor variabilidad, como nos ocurría en el caso 1, y las instancias están divididas en los clústers de manera más homogénea, mientras que con DBSCAN hay mayor diferencia entre el número de instancias en el clúster “más poblado”, el clúster 0, y en el resto.

### 2.3.4. Interpretación de la segmentación

Con los dos algoritmos considerados los atributos que mejor diferencian los distintos clústers son `TOT_VEHICULOS_IMPLICADOS` y `TOT_HERIDOS_LEVES`. No hay muchos accidentes en este caso con muertos, por lo que el atributo `TOT_MUERTOS` no ayuda mucho a diferenciar los distintos clústers. De hecho, el algoritmo DBSCAN descarta los casos con muertos y los clasifica en el clúster -1. Como comentamos anteriormente, el atributo `TOT_VICTIMAS` puede deducirse de otros atributos considerados, por lo que podríamos prescindir de él. En ambos casos, el atributo `TOT_HERIDOS_LEVES` sólo ayuda a diferenciar dos clúster de los otros siete.



#### 2.4. Caso 3: Entre semana con densidad de circulación densa

### 3. Contenido adicional

### 4. Bibliografía

#### Visualización

- <https://es.wikipedia.org/wiki/BI-RADS>
- Datos: <https://bigml.com/user/TotyB/gallery/dataset/509a98c6035d0706dd0001dd>

#### Segmentación

- Transparencias Tema 5: Clustering
- [Manual del alumno. Permiso B](#)
- <https://github.com/SofiaAlmeida/IN/blob/master/P2/memoria.pdf>
- <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html#sklearn.cluster.KMeans.fit>
- <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html#sklearn.cluster.DBSCAN>
- <https://es.wikipedia.org/wiki/DBSCAN>