

Inteligencia de Negocio. Práctica 3: Competición de Kaggle

Patricia Córdoba Hidalgo

patriciacorhid@correo.ugr.es

Grupo 2 (Viernes)

27 de diciembre de 2020

Índice

1. Introducción	3
2. Lista de intentos	4
3. Intentos	5
3.1. p3_00	5
3.2. p3_01	7
3.3. p3_02	8
3.4. p3_04	9
3.5. p3_05	12

1. Introducción

Nuestro problema consiste en predecir el precio de un conjunto de instancias de coches a partir de ciertas características de éste. Es un problema de aprendizaje supervisado, más concretamente de clasificación. Las etiquetas correspondientes a la variable `Precio.cat`, aquella que queremos predecir, son las siguientes:

1. Coches baratos.
2. Coches menos baratos.
3. Coches con precio promedio.
4. Coches más caros que el promedio.
5. Coches muy caros.

Las características de los coches usadas para predecir su precio son:

- Nombre del tipo de coche.
- Ciudad de venta del coche.
- Año del coche.
- Kilómetros recorridos del coche.
- Tipo de combustible del coche.
- Tipo de marcha.
- Mano (primera mano, segunda mano, tercera mano, cuarta o más).
- Consumo.
- CC del motor.
- Potencia del motor.
- Asientos del coche.
- Descuento realizado por oferta.

Usaré distintas técnicas y modelos para predecir las etiquetas del conjunto de test. Estas etiquetas serán subidas es un fichero llamado `p3-{número}.csv` a la plataforma Kaggle. La métrica usada para representar la bondad del ajuste es *accuracy*.

2. Lista de intentos

Archivo	Fecha	Pos.	Acc. Train	Acc. Test	Preprocesado	Algoritmos	Parámetros
p3_00.csv	13:20:11 20/12/20	7	0.826657	0.75237	Eliminación de la variable Descuento Uso de Labelencoder	Random Forest	criterion = gini n_estimators = 150 ccp_alpha=0
p3_01.csv	19:03:32 20/12/20	4	0.901557	0.76186	SMOTE	Random Forest	criterion = entropy n_estimators = 220 ccp_alpha=0.00023
p3_02.csv	15:40:15 21/12/20	4	0.900445	0.75582	Cambio de nombres por marcas	Random Forest	criterion = entropy n_estimators = 130 ccp_alpha=0
p3_04.csv	20:49:52 21/12/20	2	0.86529	0.79637	Normalización + OneHotEncoder	MLP	activation = tanh hidden_layer_sizes = (300,300) alpha=default
p3_05.csv	20:52:47 21/12/20	2	0.881868	0.68162	Normalización + OneHotEncoder	Knn	n_neighbors = 1
p3_06.csv	15:07:36 22/12/20	3	0.920356	0.79982	Normalización + OneHotEncoder	Gradient Boosting	n_estimators = 760 min_sample_leaf = 8 learning_rate = 0.1
p3_07.csv	17:25:41 22/12/20	3	0.9330367	0.80241	Normalización + OneHotEncoder	Stacking con Gradient Boosting MLP y Random Forest	final_estimator = LogisticRegression con max_iters = 400
p3_08.csv	16:53:58 24/12/20	3	0.934805	0.79376	Normalización + OneHotEncoder + LocalOutliersFactor	Stacking con Gradient Boosting MLP y Random Forest	final_estimator = LogisticRegression con max_iters = 400
p3_09.csv	20:34:30 24/12/20	3	0.9339265	0.80845	Normalización + OneHotEncoder	Stacking con Gradient Boosting MLP Random Forest y lightbmClassifier	final_estimator = LogisticRegression con max_iters = 400 ----- boosting_type = 'goos' num_leaves = 35 max_depth = 10 n_estimators = 150
p3_10.csv	20:36:50 24/12/20	1	0.930033	0.82830	Normalización + OneHotEncoder	Stacking con Gradient Boosting MLP y lightbmClassifier	final_estimator = LogisticRegression con max_iters = 400 ----- boosting_type = 'goos' num_leaves = 35 max_depth = 10 n_estimators = 150

NOTA: No consideré oportuno subir el fichero p3_03.py, se puede considerar que ese fichero es inexistente. No es ningún error que no aparezca en la tabla de intentos.

3. Intentos


3.1. p3_00

Antes de nada analizamos el conjunto de training. Con la orden `datos.info()` obtenemos los atributos que componen este conjunto, el número de instancias que componen dicho conjunto y el número de valores nulos:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4819 entries, 0 to 4818
Data columns (total 14 columns):
#   Column          Non-Null Count  Dtype
---  -
0   id              4747 non-null   float64
1   Nombre          4747 non-null   object
2   Ciudad          4747 non-null   object
3   Año             4747 non-null   float64
4   Kilometros      4747 non-null   float64
5   Combustible     4747 non-null   object
6   Tipo_marchas    4747 non-null   object
7   Mano            4747 non-null   object
8   Consumo         4746 non-null   object
9   Motor_CC        4718 non-null   object
10  Potencia        4644 non-null   object
11  Asientos        4713 non-null   float64
12  Descuento       659 non-null    float64
13  Precio_cat      4819 non-null   int64
dtypes: float64(5), int64(1), object(8)
memory usage: 527.2+ KB
```

La variable Descuento posee más valores nulos que el resto, un total de 4160 valores perdidos.

Tras esto representamos el número de elementos por clase y observamos que las clases están desbalanceadas:



(a) Datos en cada clase

Una vez que tenemos una idea de la distribución de los datos, pasamos a trabajar con ellos. Primero trabajamos con los valores perdidos. Si eliminásemos todos los valores perdidos, contaríamos sólo con el 11.68 % de los originales, con lo que perderíamos mucha información, así que descarté ese preprocesamiento.

El preprocesamiento que realicé finalmente consiste en eliminar la variable Descuento, ya que el 86.32% de sus valores son perdidos y eliminar el resto de valores perdidos restantes. Esto supone quedarnos con el 81.88% de los datos originales. Reorganicé los índices para que fuesen del 1 al 3945, dado que posteriormente será necesario esta numeración para recorrer el dataframe con bucles. Esto fue realizado con el código:

```
1 p2_datos = datos.copy()
2 del(p2_datos['Descuento'])
3 p2_datos = p2_datos.dropna()
4 p2_datos = p2_datos.reset_index()
5 del(p2_datos['index'])
```

Tras esto se cuantificaron todas las variables cuaitativas usando **LabelEncoder**. El **LabelEncoder** entrena con la lista total de los valores de cada atributo, que se encuentra en los ficheros *.csv* correspondientes a cada uno, y se usa para transformar los datos *train* y *test*. De esta manera, se aplica la misma transformación en ambos.

Las variables *Consumo*, *Motor_CC* y *Potencia* están codificadas como **string**. Para guardarlas como un **float**, eliminamos las unidades que acompañan a los valores de estas variables. Por ejemplo, el código usado para eliminar la unidad “ kmlp” en la variable *Consumo* es:

```
1 for i in range(len(p2_datos)):
2     p2_datos["Consumo"].iloc[i] = float(p2_datos["Consumo"].iloc[i].strip(' kmlp'))
```


Una vez preprocesados los datos, separamos las etiquetas del resto de variables:

```
1 cols = [col for col in p2_datos.columns if col not in ['Precio_cat']]
2 data = p2_datos[cols]
3 del(data['id'])
4 target = p2_datos['Precio_cat']
```


Por último elegí el algoritmo **Random Forest** para resolver este problema y seleccioné los hiperparámetros que iba a usar. Para evaluar la bondad del modelo con cada uno de los diferentes hiperparámetros usé la media de la medida *accuracy* conseguida con cada uno de los cinco conjuntos usados en validación cruzada.

Como criterio de división de nodos, usé el **gini**, ya que la *accuracy* media obtenida es 0.826657682373137 mientras que con **entropy** consigue un 0.8215879738813753.

Para elegir el número de estimadores usados, probé con diversas cantidades, obteniendo los resultados mostrados en las siguientes gráficas:




(b) Selección de **n_estimators**



(c) Selección de **n_estimators**

En la primera vemos que el máximo se alcanza entorno a 150 estimadores, por lo que realicé intentos menos espaciados entorno a este número. Se aprecia que el máximo se sigue alcanzando en 150 estimadores, que es el valor por defecto de este parámetro.

También intenté identificar el parámetro de poda óptimo. Podemos comprobar que la poda empeora el desempeño del modelo, por lo que este parámetro tampoco lo modificaremos.



(d) Selección de `ccp_alpha`

Tras todo el ajuste de hiperparámetros, el modelo final es aquel por defecto. Por tanto, para ver la *accuracy* del modelo ejecutamos el siguiente código:

```
1 rf_clf = RandomForestClassifier(random_state=15, n_estimators=150)
2 score = cross_val_score(rf_clf, data, target, cv=5)
3
4 s = 0
5 for i in range(len(score)):
6     s+= score[i]
7
8 print("La accuracy del modelo es: " + str(s/len(score)))
```

La *accuracy* del modelo en el conjunto training es: 0.826657682373137. Tras aplicar el mismo preprocesado al conjunto test, obtenemos que la *accuracy* del conjunto test es 0.75237.

3.2. p3.01

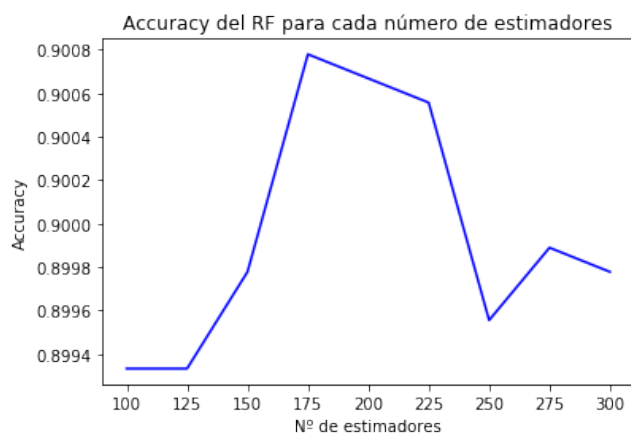
En este intento, tras aplicar el preprocesamiento explicado en la prueba anterior, aplicamos SMOTE (Synthetic Minority Oversampling Technique). Con esto conseguimos que las clases estén balanceadas. El código usado para llevar esto a cabo es:

```
1 data, target = SMOTE(random_state=15).fit_resample(data, target)
```


Si ejecutamos la orden `Counter(target)`, comprobamos que todas las clases tienen 1798 instancias.

Después de procesar así los datos, volvemos a ajustar los hiperparámetros del algoritmo **Random Forest**. Esta vez, el criterio de división escogido es **entropy**, que consigue una *accuracy* media de 0.8997775305895438 frente a 0.8972191323692993 que se consigue usando **gini**. Podemos observar que la *accuracy* que consigue el conjunto train con este procesamiento es mayor que sin aplicar oversampling.

Estimamos el número óptimo de estimadores de igual manera que en el intento anterior:




(e) Selección de `n_estimators`



(f) Selección de `n_estimators`

A la vista de los resultados tomamos 220 estimadores. También estimamos el valor del parámetro de poda. Escogemos 0.00023 dados los resultados obtenidos en la siguiente gráfica:



(g) Selección de `ccp_alpha`

La *accuracy* del modelo en el conjunto training es 0.9015572858731924. Tras aplicar el mismo preprocesado al conjunto test, obtenemos que la *accuracy* del conjunto test es 0.76186.

3.3. p3.02

En este intento, después de eliminar la variable Descuento y los valores nulos, y antes de usar `LabelEncoder`, sustituí los nombres de los coches por las marcas de los coches usando el siguiente código:

```

1 for i in range(len(nombre)):
2     nombre["Nombre"].iloc[i] = nombre["Nombre"].iloc[i].split('_')[0]
3
4 for i in range(len(p2_datos)):
5     p2_datos["Nombre"].iloc[i] = p2_datos["Nombre"].iloc[i].split('_')[0]
```


El resto del preprocesamiento se mantuvo. Volví a seleccionar los hiperparámetros del **Random Forest**:

El criterio de división elegido fue **entropy**, que consigue una *accuracy* de 0.8994438264738598 frente a 0.8957730812013349 que consigue el criterio **gini**.

Seleccionamos el número de estimadores usado, que en este caso será 130, por la información representada en las siguientes gráficas:




(h) Selección de `n_estimators`



(i) Selección de `n_estimators`

También decidí usar el valor 0 para el parámetro de poda. El motivo se encuentra en la siguiente gráfica:



(j) Selección de `ccp.alpha`

La *accuracy* del modelo en el conjunto training es 0.9004449388209121. Aunque es inferior a la obtenida en el intento anterior, pensé que con este procesamiento podría reducirse el sobreajuste y obtener mejores resultados en el conjunto test. Tras aplicar el mismo preprocesado al conjunto test, obtenemos que la *accuracy* del conjunto test es 0.75582, por tanto mis sospechas no eran ciertas.

3.4. p3_04

En este intento quise probar con un modelo diferente, **MLP**. Este modelo requiere un preprocesado diferente, ya que la normalización y el uso de **OneHotVectors** hace que el modelo obtenga mejores resultados.

El procesamiento usado en esta prueba consiste entonces en eliminar, como en las anteriores, la variable Descuento y los valores nulos restantes. Luego pasamos los nombres de los coches a marcas, del mismo modo que hicimos en p3_02, para reducir así el número de variables finales (habrá una variable por cada posible valor del atributo cualitativo al que apliquemos **OneHotEncoder**).

En vez de aplicar **LabelEncoder** a las variables cualitativas, usé **OneHotEncoder**. Esto nos crea una nueva variable por cada uno de los posibles valores que tomase la variable a la que se lo aplicamos. Añadimos estas variables al

DataFrame de datos y eliminamos la variable original. Un ejemplo del código usado para esto es:

```

1 encCiudad = OneHotEncoder(handle_unknown='ignore')
2 encCiudad.fit(ciudad["Ciudad"].to_numpy().reshape(-1, 1))
3 aux = encCiudad.transform(p2_datos["Ciudad"].to_numpy().reshape(-1, 1)).toarray()
4 aux = pd.DataFrame(aux)
5
6 for i in range(aux.shape[1]):
7     p2_datos["Ciudad_" + str(i)] = aux[i]
8
9 del(p2_datos['Ciudad'])

```

Tras esto, volvemos a eliminar las unidades de las variables *Consumo*, *Motor_CC* y *Potencia* como se explicó en p3_00 y así pasar a float sus valores.

La estructura de los datos es ahora:

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 3946 entries, 0 to 3945
```

```
Data columns (total 61 columns):
```

#	Column	Non-Null Count	Dtype
0	id	3946 non-null	float64
1	Año	3946 non-null	float64
2	Kilometros	3946 non-null	float64
3	Consumo	3946 non-null	float64
4	Motor_CC	3946 non-null	float64
5	Potencia	3946 non-null	float64
6	Asientos	3946 non-null	float64
7	Precio_cat	3946 non-null	int64
8	Nombre 0	3946 non-null	float64
9	Nombre 1	3946 non-null	float64
10	Nombre 2	3946 non-null	float64
11	Nombre 3	3946 non-null	float64
12	Nombre 4	3946 non-null	float64
13	Nombre 5	3946 non-null	float64
14	Nombre 6	3946 non-null	float64
15	Nombre 7	3946 non-null	float64
16	Nombre 8	3946 non-null	float64
17	Nombre 9	3946 non-null	float64
18	Nombre 10	3946 non-null	float64
19	Nombre 11	3946 non-null	float64
20	Nombre 12	3946 non-null	float64
21	Nombre 13	3946 non-null	float64
22	Nombre 14	3946 non-null	float64
23	Nombre 15	3946 non-null	float64
24	Nombre 16	3946 non-null	float64
25	Nombre 17	3946 non-null	float64
26	Nombre 18	3946 non-null	float64
27	Nombre 19	3946 non-null	float64
28	Nombre 20	3946 non-null	float64
29	Nombre 21	3946 non-null	float64
30	Nombre 22	3946 non-null	float64
31	Nombre 23	3946 non-null	float64
32	Nombre 24	3946 non-null	float64
33	Nombre 25	3946 non-null	float64
34	Nombre 26	3946 non-null	float64
35	Nombre 27	3946 non-null	float64

36	Nombre	28	3946	non-null	float64
37	Nombre	29	3946	non-null	float64
38	Nombre	30	3946	non-null	float64
39	Ciudad	0	3946	non-null	float64
40	Ciudad	1	3946	non-null	float64
41	Ciudad	2	3946	non-null	float64
42	Ciudad	3	3946	non-null	float64
43	Ciudad	4	3946	non-null	float64
44	Ciudad	5	3946	non-null	float64
45	Ciudad	6	3946	non-null	float64
46	Ciudad	7	3946	non-null	float64
47	Ciudad	8	3946	non-null	float64
48	Ciudad	9	3946	non-null	float64
49	Ciudad	10	3946	non-null	float64
50	Combustible	0	3946	non-null	float64
51	Combustible	1	3946	non-null	float64
52	Combustible	2	3946	non-null	float64
53	Combustible	3	3946	non-null	float64
54	Combustible	4	3946	non-null	float64
55	Tipo_marchas	0	3946	non-null	float64
56	Tipo_marchas	1	3946	non-null	float64
57	Mano	0	3946	non-null	float64
58	Mano	1	3946	non-null	float64
59	Mano	2	3946	non-null	float64
60	Mano	3	3946	non-null	float64

dtypes: float64(60), int64(1)

memory usage: 1.8 MB

Como vemos, ahora hay 61 variables en vez de 13 (14 menos el Descuento) y no hay valores nulos.


Por último, normalizamos los datos de las variables cuantitativas usando `MinMaxScaler`. Como siempre, entrenamos con el archivo con los posibles valores de la variable y luego aplicamos la misma transformación a los datos training y test. Un ejemplo del código usado para normalizar es:

```

1 scalerKilometros = MinMaxScaler()
2 scalerKilometros.fit(kilometros["Kilometros"].to_numpy().reshape(-1, 1))
3 aux = scalerKilometros.transform(p2_datos["Kilometros"].to_numpy().reshape(-1, 1))
4 aux = pd.DataFrame(aux)
5 p2_datos["Kilometros"] = aux[0]

```

Una vez hecho esto, separamos los datos de las etiquetas, aplicamos oversampling y ajustamos los hiperparámetros de MLP. Para este algoritmo, el parámetro que estimamos es `hidden_layer_sizes`.



(k) Selección de `hidden_layer_sizes`

La *accuracy* del modelo en el conjunto training es 0.8652947719688543. Tras aplicar el mismo preprocesado al conjunto test, obtenemos que la *accuracy* del conjunto test es 0.79637.

3.5. p3_05